01/03/2023

Rapport du cas pratique

Bertrand BOREL
ECOLE MICROSOFT IA & SIMPLON

Table des matières

1. Introduction

Le présent rapport vise à résumer en détail la solution que nous avons déployée pour résoudre le cas pratique qui nous était proposé.

Nous commencerons par évoquer les objectifs du cas pratique pour bien comprendre le sujet puis nous détaillerons la solution que nous avons proposée, à savoir un modèle de reconnaissance d'intelligence artificielle basé sur de la vidéo.

Par la suite nous traiterons de la question des images sur lesquelles nous avons entraîné le modèle, puis de la labellisation des données et du modèle que nous avons pu produire.

Enfin nous parlerons de l'application que nous avons mise en place, afin de répondre au besoin de l'entreprise cliente.

2. Objectif du cas pratique :

L'entreprise Utop-IA, spécialisée dans les technologies de surveillance et de sécurité, a créé une application d'IA qui peut détecter et localiser la présence d'un casque de chantier à partir d'une vidéo. Ils cherchent maintenant à améliorer cette application pour inclure la détection et la localisation des gilets de sécurité, en déterminant si une personne les porte ou non.

L'objectif du cas pratique est d'améliorer une application de détection d'images. L'utilisateur (en l'occurrence un travailleur et un visiteur d'un chantier) doit porter un casque et un gilet à bandes réfléchissantes. L'application renvoie un message confirmant ou non le port des deux objets. Cette application vise à respecter les consignes et les règles encadrant les chantiers, quelque soit leur nature, et d'assurer d'évoluer en toute sécurité.

A noter que l'application développée par l'entreprise Utop-IA utilise *Streamlit-webrtc*, elle utilise la webcam de l'ordinateur et affiche le résultat de la détection.

L'objectif de ce rapport est de décrire en détail notre application et préciser en quoi cette dernière répond parfaitement aux demandes de l'entreprise. En effet, notre application assure les fonctions suivantes :

- Détection et/ou localisation de la présence/absence du gilet de sécurité.
- Affiche un message d'alerte sur la page web (en dehors de la vidéo) si une seule personne ne porte pas son casque ou son gilet.

Nous avons choisi d'utiliser Yolov5, notamment la version 6.2[1], qui est très performante dans la détection d'objet. Yolov5 dispose par ailleurs de modèles pré-entraînés sur le *dataset* COCO[2]. Ce choix nous a permis de gagner du temps dans l'entraînement du modèle : étant donné qu'il s'agit de *transfer learning*, nous disposons d'une architecture et d'un modèle déjà pré-entraîné et n'avons plus qu'à personnaliser notre modèle.

Nous avons entraîné notre modèle sur plus de 1000 photos. Le plus long a été des rassembler les images et de les labelliser. Nous avons trouvé une partie des images dans des *datasets* d'images en accès libre et avons constitué notre propre base d'images en sélectionnant des images libres de droits sur internet.

La solution Yolo était la plus simple et la plus rapide à mettre en place : nous n'avions pas à créer un modèle du début à la fin et le modèle était déjà pré-entrainé, comme nous l'évoquerons plus tard dans ce rapport.

3. Traitement des images :

Les images de départ n'étant pas assez nombreuses, un premier entraînement du modèle nous donnait de mauvais résultat. Nous avions choisi de le construire de la manière suivante : une taille de *bach* (lot) de 75 sur 100 *epochs*. La raison d'un *batch* si élevée vient du fait que plus il y a d'images dans un *batch* et plus les fluctuations stochastiques sont réduites lors de l'apprentissage du modèle. Cependant la taille élevée augmente

[1] https://github.com/ultralytics/yolov5
[2] https://cocodataset.org/#home

considérablement la puissance requise pour aller au bout de tous les calculs, ce qui demande d'importantes ressources.

Par ailleurs, une taille de *batch* trop élevée peut conduire au sur-apprentissage du modèle (*overfitting*). Le modèle a parfaitement appris sur le jeu de données, mais est incapable de généraliser sur des données nouvelles : il est donc inexploitable. Ce fut notre cas, le sur-apprentissage étant flagrant, le modèle ne parvenant ni à détecter les gilets ni à détecter les casques sur les images qu'on lui proposait.

L'échec de ce premier modèle nous a fait choisir une taille de *batch* beaucoup plus faible. Ce changement a été contrebalancé par un nombre d'*epochs* plus grand. De plus nous avons pris la décision d'augmenter le nombre d'images que notre jeu de données contenait au départ.

Pour réaliser cela, nous avons choisi :

- D'intégrer de nouvelles images
- D'avoir recourt à de la *data augmentation*.

Par ailleurs nous avons opté pour ajouter de nouvelles images qui répondaient aux points suivants :

- Varier les couleurs des gilets et de casques :
    - Gilets de couleurs différentes (très bon résultat sur la couleur jaune, correcte sur orange, difficile avec d'autres couleurs, comme le rouge ou le vert).
    - Casque de couleurs différentes : blanc, rouge, orange, bleu... Il a fallu cerner les couleurs les moins fréquentes pour les représenter plus largement dans le jeu de données. Si un casque vert était présenté, le modèle risquait de ne pas le reconnaître comme tel.
- Varier les formes des gilets et des casques (de chantier) :
    - Formes du gilet : s'il est ouvert, il présente le risque de ne pas être reconnu.
    - Formes du casque : certains casques de chantiers présentent une visière de protection (notamment pour protéger les yeux de l'utilisateur d'éventuelles projections). Ce genre de casque peut être confondu avec des casques de motos (fermés) par exemple.

- Nous avons également testé la pertinence du modèle avec différents types de chapeaux pour voir si l'apprentissage se révélait pertinent ou non. Ainsi un casque de moto n'est pas reconnu, mais un casque de vélo peut tromper le modèle.

En outre avons aussi fait attention aux points suivant :

- Variation du sexe (les femmes sont plus rares sur les chantiers selon les statistiques) : il fallait que le modèle puisse reconnaître une femme, s'il y avait trop peu de données, le résultat ne pouvait être que faussé. Pour éviter cette situation nous avons augmenté le nombre de photos de femmes.
- Variation de l'origine ethnique : si le modèle était uniquement entraîné sur des données représentant le type européen il produirait de mauvais résultats sur d'autres données.
- Variation de l'âge : la donnée la plus difficile à obtenir, car il y a peu de représentation de personnes âgées (ou de personnes ayant simplement des cheveux blancs) sur un chantier. Nous avons cependant réussi à augmenter le nombre d'images dans cette catégorie.

Exemples d'images

Figure 1

Figure 2

Figure 3

4. Labélisation des données :

Les données ont été réparties en 4 classes :

- avec casque
- avec gilet
- sans casque
- sans gilet

Pour notre premier modèle, nous avons constaté un déséquilibre entre les différents labels : il y avait moins de gilets représentés et peu de personnes ne portant pas un casque de sécurité.

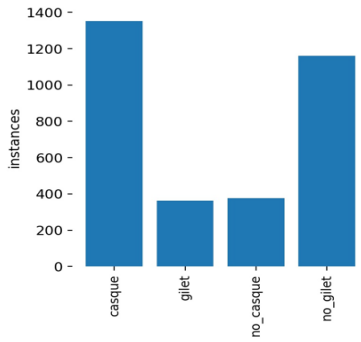

Les personnes portant un gilet et pas de casque auraient été plus difficiles à détecter pour notre modèle, car il n'avait pas été entraîné avec autant d'images que les autres labels. Pour obtenir de meilleurs résultats, nous avons choisi d'augmenter le nombre d'images des labels en question, comme l'illustre le diagramme suivant.

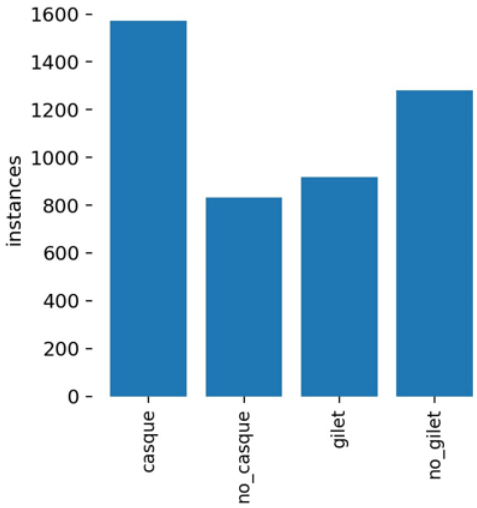

5. Description du modèle :

a) Entraînement du modèle :

Notre modèle a été entraîné sur plus de 1000 photos, avec un *batch-size* fixé à 16 et 300 *epochs*. Plusieurs tentatives ont été réalisées avec un échantillon plus ou moins élevé pour le *batch* et en variant le nombre d'*epochs*. Le modèle que nous avons choisi de retenir pour ce cas pratique n'est pas le meilleur sur le papier (ses résultats de prédiction pouvant être améliorés), mais il fonctionne correctement en pratique. Entre la performance et l'efficacité, nous avons choisi la deuxième option.

b) Structure du modèle :

Les modèles pré-entraînés de Yolov5 sont des réseaux de neurones de types convolutifs (*CNN* : *Convolutional neural network*). Ce type de réseau de neurones est le plus efficace en ce qui concerne la reconnaissance d'images.

Prenons un exemple simple : une image de 250 pixels sur 250 contient 62 500 pixels (250*250=62500). Si l'on attribue un pixel à un neurone, notre réseau devrait contenir 62 500 neurones. Pour un réseau multicouche, avec seulement 3 couches, cela nous donnerait 187 500 neurones. Le réseau serait très compliqué, voire impossible à mettre en place, et ne serait pas rentable.

La solution est de passer par un *CNN* : la première partie du réseau vise à extraire les caractéristiques importantes des images (*feature maps*) et de réduire au fur et à mesure l'information circulant dans le réseau à quelques échantillons qui sont ensuite transmis à la deuxième partie du réseau, qui a pour but d'effectuer la phase de reconnaissance.

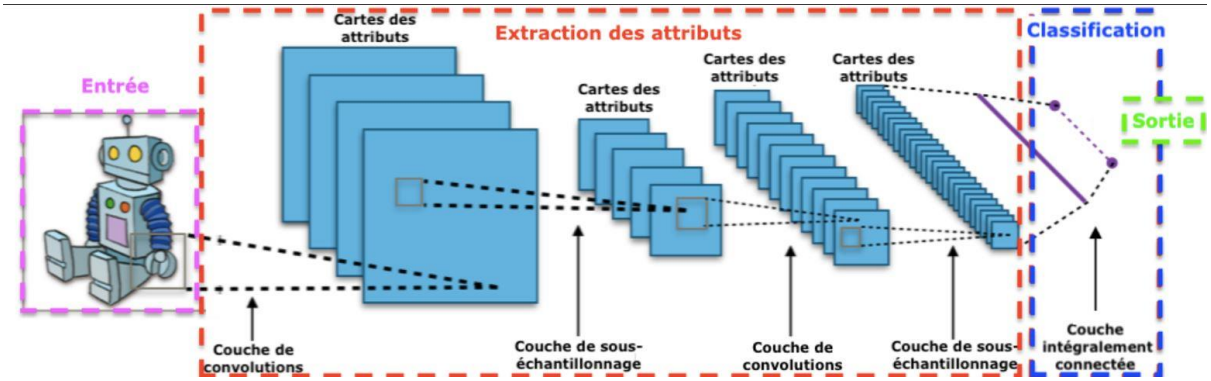

Figure 4- Architecture d'un CNN[3]

c) Métriques du modèle :

i. Matrice de confusion :

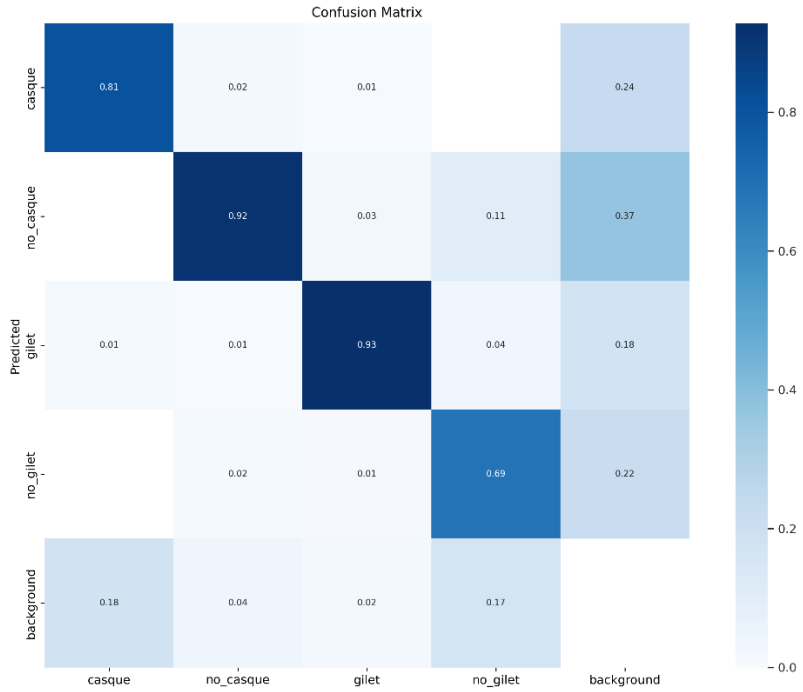

La matrice de confusion du modèle final nous renvoie de très bon résultat pour les prédictions sans casque et les prédictions avec gilet (respectivement 0.92 et 0.93). Les résultats baissent avec les prédictions du casque (0.81) et chutent drastiquement avec les prédictions de sans gilet (0.69). Pour améliorer les performances de notre modèle, il faudrait

[3] Source de l'image : article « réseau neuronal convolutif » de wikipédia, https://fr.wikipedia.org/wiki/R%C3%A9seau_neuronal_convolutif#/media/Fichier:Typical_cnn_fr.png .

renforcer l'apprentissage sur ces deux dernières catégories, notamment en rajoutant des images adéquates.

ii. Fonction de perte et précision

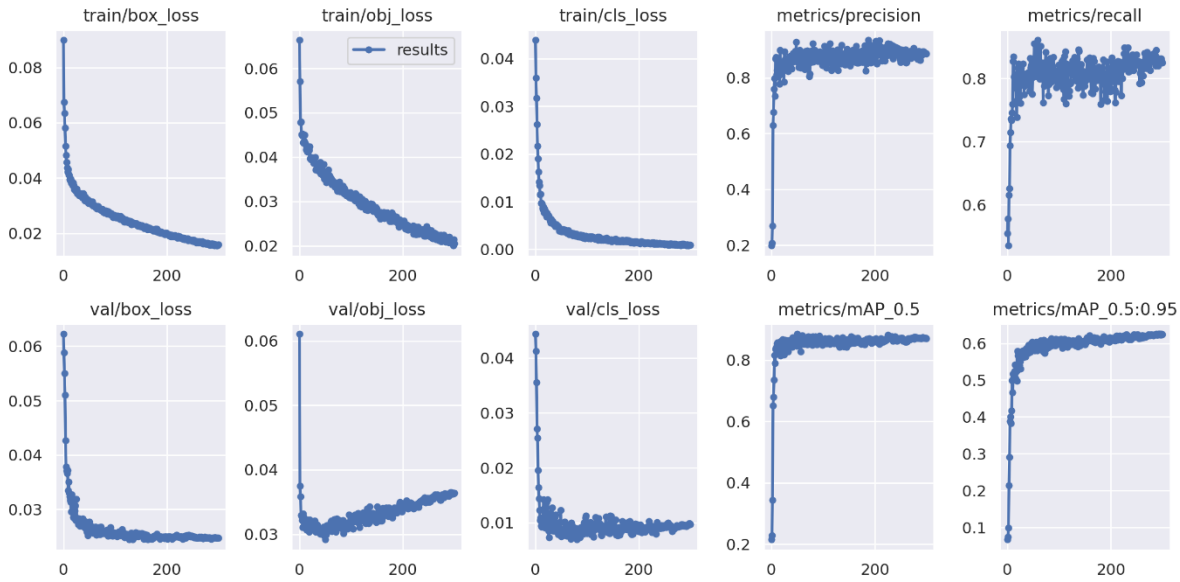

Ce document nous permet de comprendre que notre fonction coût (ou de perte : *loss*) décroît avec le temps, c'est-à-dire plus le nombre d'*epochs* augmente. Cela est vrai et très visible sur notre jeu d'entraînement (*train*) mais l'est beaucoup moins sur notre jeu de validation (*val*) : il faut se méfier du surapprentissage de notre modèle.

Notre taux de précision (Vrai positif / Vrai positif + Faux positif), c'est-à-dire combien de fois nous avons correctement classifié notre prédiction positive est bon très rapidement, il gagne quelques points en augmentant le nombre d'*epochs* mais cela reste très limité.

Notre taux de *recall*, c'est-à-dire combien de fois nous avons classifié à tort quelque chose comme faux (Vrai positif / (Vrai positif + Faux négatif). Ces deux métriques nous permettent d'avoir une meilleure idée de la pertinence de notre modèle que la simple *accuracy*.

iii. F1 score

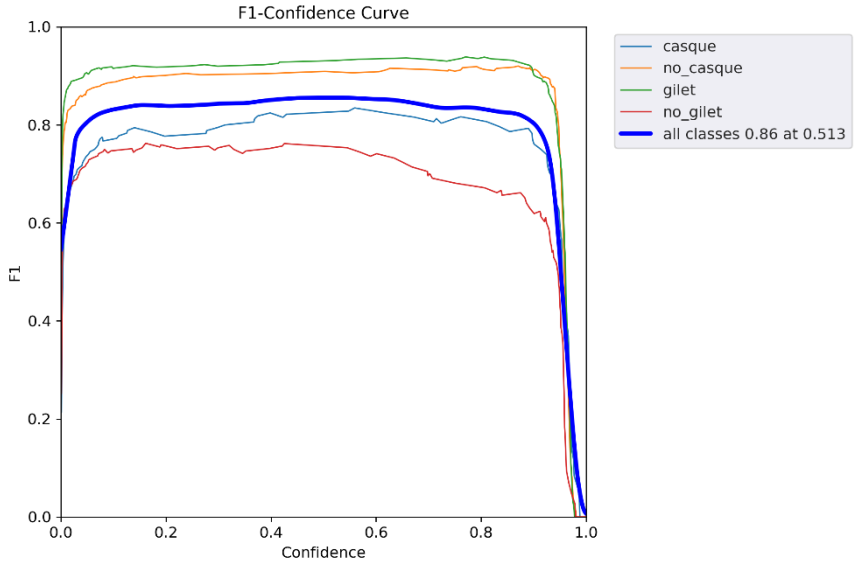

Rassemble la précision et le *recall* et fait la moyenne des deux (2 * ((Precision * Recall) / (Precision + Recall))). Le F1 score a l'avantage de produire un équilibre entre les deux métriques. Un bon résultat pour le F1 score signifie qu'il y a peu de faux positifs et peu de faux négatifs

6. L'application :

a) Fonctionnement

L'utilisateur doit se présenter face caméra. S'il a un gilet et un casque, alors l'application lui indique par message que sa tenue est correcte. Si un des éléments manque, alors l'application affiche le message contraire. Il y a juste un bouton pour lancer ou stopper la détection.

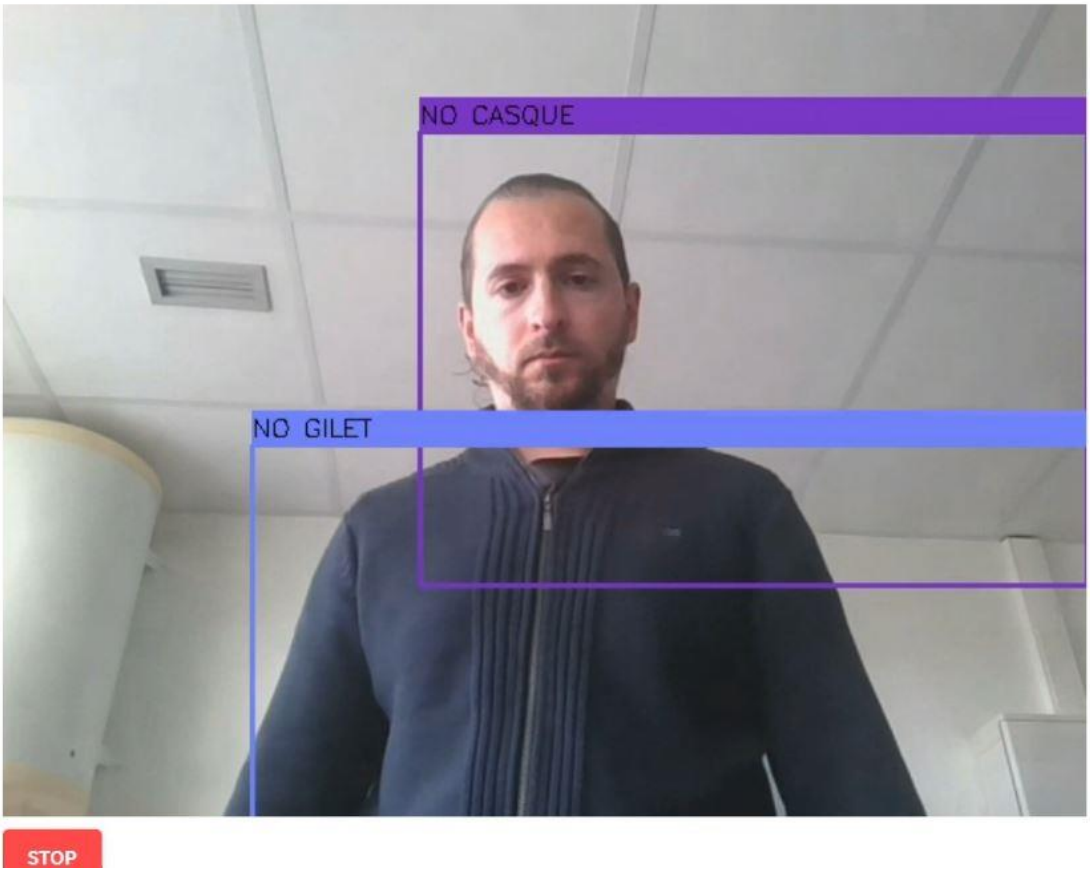

Figure 5- Capture d'écran de l'application : l'utilisateur n'a ni casque, ni gilet.

b) Affichage du message

Pour permettre d'afficher le message, nous avons choisi de stocker le résultat dans un fichier texte et d'écraser le résultat à chaque nouvelle reconnaissance.

L'application affiche le message indiquant le bon respect (ou non) du port du casque et du gilet à partir du fichier texte.

Le message est affiché sous l'espace de capture vidéo (sous le bouton de démarrage et d'arrêt de la détection) et il peut être affiché dans la console si besoin.

Figure 6- L'utilisateur porte un gilet et un casque.

Figure 7- L'utilisateur porte un gilet mais pas de casque.

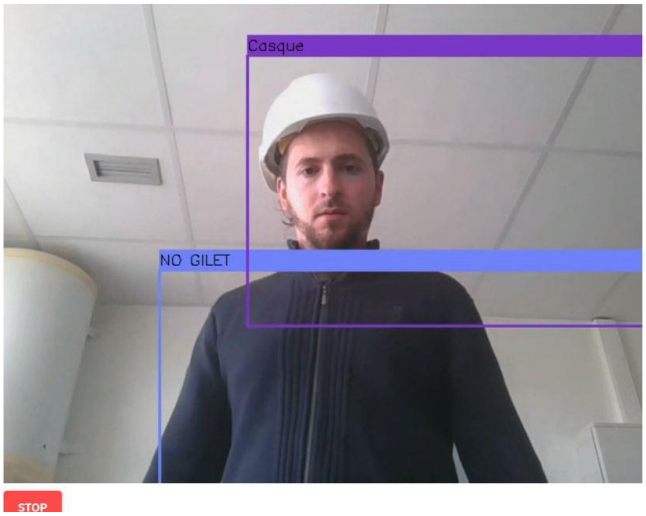

Figure 8- L'utilisateur porte un casque, mais pas de gilet.

7. Conclusion :

Au terme de ce cas pratique, nous pouvons affirmer que notre application fonctionne et répond au cahier des charges. Les résultats de la reconnaissance sont corrects. En pistes d'amélioration nous pouvons proposer :

- D'entraîner notre modèle à détecter les personnes, puis un autre modèle pour détecter les casques et les gilets.
- D'entraîner un nouveau modèle avec encore plus de données et en variant les paramètres d'apprentissage.
- De trouver un autre *framework*, peut-être plus performant que *streamlit*.
- De se tourner vers un modèle *VGG-16* et d'observer la qualité des résultats obtenus.
- D'essayer l'apprentissage semi-supervisé pour avoir des images avec labels et des images sans. Cela permettrait de gagner un temps précieux et de ne pas labéliser toutes les images, tout en augmentant leur nombre.